

PCL点云库—关键点



目录

01

NARF关键点

02

Harris关键点

03

Sift关键点

一、NARF关键点

NARF (Normal Aligned Radial Feature) 关键点是为了从深度图像中识别物体而提出的, 关键点探测的重要一步是减少特征提取时的搜索空间, 把重点放在重要的结构上, 对 NARF 关键点提取过程有以下要求: 提取的过程必须将边缘以及物体表面变化信息考虑在内; 关键点的位置必须稳定, 可以被重复探测, 即使换了不同的视角; 关键点所在的位置必须有稳定的支持区域, 可以计算描述子并进行唯一的法向量估计。为了满足上述要求, 提出以下探测步骤来进行关键点提取:

- (1) 遍历每个深度图像点, 通过寻找在近邻区域有深度突变的位置进行边缘检测。
- (2) 遍历每个深度图像点, 根据近邻区域的表面变化决定一种测度表面变化的系数, 以及变化的主方向。
- (3) 根据第二步找到的主方向计算兴趣值, 表征该方向与其他方向的不同, 以及该处表面的变化情况, 即该点有多稳定。
- (4) 对兴趣值进行平滑过滤。
- (5) 进行无最大值压缩找到最终的关键点, 即为 NARF 关键点。

NARF—边缘提取

论文将点分为三种类型: *object borders* , *shadow borders* , *veil points* .




Fig. 2. Different kinds of border points.

NARF—边缘提取

论文提出“提取边缘的最鲁棒的指导原则是：相邻点之间的距离变化 (is a change in the distance between neighboring points)”。

因此边缘提取的算法就是基于这个指导原则进行的。

对于每一个 range image 中的点 P_i :

1. 使用启发式方法寻找不跨越边缘的相邻点的3D距离
2. 使用 (1) 得到的距离信息，计算该点是边缘点的可信度(score)
3. 如果是边缘点，将该点分为上述3类点中的一类
4. 非极大抑制以获得精确的边缘点位置

NARF—边缘提取

1. 使用启发式方法寻找不跨越边缘的相邻点的典型3D距离

1. 对每一个 range image 中的点 p_i ，选择其2D平面内的一个方形窗内的邻域点，记为 $N_{p_i} = \{n_1, n_2, \dots, n_{s^2}\}$ ，其中 s 为窗宽
2. 计算 p_i 与 N_{p_i} 内每个点的3D距离(欧氏距离)，得到 $D_{p_i} = \{d_0, d_1, \dots, d_{s^2}\}$ ，对 D_{p_i} 按升序排列，得到 $D'_{p_i} = \{d'_0, d'_1, \dots, d'_{s^2}\}$
3. 假设 N_{p_i} 中至少有 M 个点与 p_i 位于同一表面，我们选取 $\mathcal{S} = d'_M$ 作为 p_i 的 $p_i - s$ 邻域内的、不考虑邻域内非共面点的典型3D距离(typical 3D distance)

Note：关于 M 和 s 的选取，论文选择 $s = 5$ ， $M = (\frac{s+1}{2})^2$ 。为了自适应，可以选择距离 d_j 跳变的点作为 M

NARF—边缘提取

2. 使用 (1) 得到的距离信息，计算该点是边缘点的可信度(score)

对点 p_i ，计算四个分数值，分别表示点的上、左、右、下方存在边缘的可能(下面仅以 right 方向为例，其他方向计算方法相似)：

notation: $p_{x,y}$ 表示图片中 (x, y) 位置处的点

1. 首先计算右边点的平均距离

$$p_{right} = \frac{1}{m_p} \sum_{i=1}^{m_p} p_{x+i,y} \quad (1)$$

其中 m_p 为考虑的右边点的个数，论文中采用 $m_p = 3$

2. 计算3D距离 $d_{right} = ||p_{x,y} - p_{right}||$

这个距离是右边3个像素对应点的平均距离。当平面点距离delta的值小于dr的时候代表可能是边缘的点

3. 计算 $s_{right} \in [0, 1)$

$$s_{right} = \max(0, 1 - \frac{\delta}{d_{right}}) \quad (2)$$

s_{right} 值越大，表明点 p_i 右边距离变化越明显，则存在边缘的概率越大。

4. 对得到的 S_{right} 图进行平滑操作，以得到连续的边缘同时提高对噪声的鲁棒性

NARF—边缘提取

3. 如果是边缘点，将该点分为上述3类点中的一类

1. 确定 $p_{x,y}$ 所属的点的类型：根据 $p_{x,y}$ 与 p_{right} 的3D距离的比较， $p_{x,y}$ 距离更小则表明可能是 *obstacle border* 否则可能是 *shadow border*。
2. 对所有可能是 *obstacle border* 的点，在2D平面内搜索其右侧对应的 *shadow border*。选择2D平面上右边 m_p 范围内3D距离最大的点作为对应的 *shadow border* 并计算 s_{shadow} 。对 s_{right} 做如下调整：

Shadow得分的计算使用公式（2），
把分子delta换成shadow的距离

$$s'_{right} = \max(0.9, 1 - (1 - s_{shadow})^3) \times s_{right} \quad (3)$$

4. 非极大抑制以获得精确的边缘点位置

如果 s'_{right} 大于阈值(论文中取 0.8)，并且是 $(p_{x-1,y}, p_{x+1,y})$ 邻域内的极大值，则认为 $p_{x,y}$ 为 *obstacle border*，(4.6) 中找到的对应的 *shadow point* 即其对应的 *shadow border*，位于两者之间的点就是 *veil point*

NARF—特征点提取

特征点提取的指导原则如下：

1. 必须考虑边缘和表面结构信息
2. 必须是能在不同视角下都能被检测到的点
3. 必须位于稳定的区域，从而可以得到的稳定的法向量

步骤如下：

1. 对 range image 中的每一个点，计算一个表示其邻域表面变化的分数和这种变化的一个主方向(dominant direction)
2. 对每个点，根据邻域点的dominant direction 计算一个 interest value，该值表达了两个性质：
 - a). 邻域内点的dominant directions 之间的差异
 - b). 该点所处的表面的局部变化量(表面的稳定程度)。
3. 对 interest value 图进行平滑
4. 非极大抑制，找到最终的 interest points

NARF—特征点提取

1. 估计法向量：对每个点 $p_i \in RangeImage$ ，利用其2D邻域内欧氏距离在 2δ 内的点的3D位置和PCA 算法，估计其法向量。
2. 对 range image 中的每一个点，计算一个表示其邻域表面变化的分数和这种变化的一个主方向(dominant direction)
 1. 计算主方向 v 和幅值 λ ：对于 borders point， v 为边缘方向；对于 others point， v 为主曲率方向(main direction of the curvature)， λ 为方向的幅值。
 2. 对每个 v ，都赋一个权值 $w \in [0, 1)$ ：对 borders point， $w = 1$ ；对 others point， $w = 1 - (1 - \lambda)^3$ 。
 3. 指定一个参数 σ 表示 support size。对图像中的每个点 p ，找到其所有欧氏距离在 $\frac{\sigma}{2}$ 内且中间不存在边缘(两点位于同一表面上)的点，记为 $N_p = \{p_0, p_1, \dots, p_N\}$ 。
 4. 对 $\forall p_i \in N_p$ ，将 v_{p_i} 投影到一个平面 P 上 (P 为垂直于 p 到原点连线的一个平面)，得到一个角度 α_{p_i} 。对 α_{p_i} 作如下调整
我们将主方向投影到垂直于从传感器到 p 的方向的平面上

$$\alpha' = \begin{cases} 2 \cdot (\alpha - 180^\circ) & \text{for } \alpha > 90^\circ \\ 2 \cdot (\alpha + 180^\circ) & \text{for } \alpha \leq -90^\circ \end{cases} \quad (4)$$

5. 使用 bounded Gaussian kernel 对 w 和 α 进行平滑

6. 计算 interest value:

$$I_1(p) = \min_i \left(1 - w_{n_i} \max\left(1 - \frac{10 \cdot \|p - n_i\|}{\sigma}, 0\right) \right) \quad (5)$$

$$f(n) = \sqrt{w_n \left(1 - \left| \frac{2 \cdot \|p - n\|}{\sigma} - \frac{1}{2} \right| \right)} \quad (6)$$

$$I_2(p) = \max_{i,j} (f(n_i) f(n_j) (1 - |\cos(\alpha'_{n_i} - \alpha'_{n_j})|)) \quad (7)$$

$$I(p) = I_1(p) \cdot I_2(p) \quad (8)$$

<https://blog.csdn.net/memorynode>

3. 非极大抑制，找到最终的 interest points

PCA点云法向量估计

基于PCA的点云法向量估计，其实是从最小二乘法推导出来的。假设我们要估计某一点的法向量，我们需要通过利用该点的近邻点估计出一个平面，然后我们就能计算出该点的法向量。或者可以这么说，通过最小化一个目标函数（要求的参数为法向量），使得该点与其每个近邻点所构成的向量与法向量的点乘为0，也就是垂直：

$$\min_{\mathbf{c}, \mathbf{n}, \|\mathbf{n}\|=1} \sum_{i=1}^n ((\mathbf{x}_i - \mathbf{c})^T \mathbf{n})^2$$

<https://blog.csdn.net/linmingan>

正常情况下，我们可以将点 \mathbf{c} 看成是某一领域中所有点的中心点：

$$m = \frac{1}{n} \sum_{i=1}^n X_i$$

优化目标函数变为：

$$\min_{\|\mathbf{n}\|=1} \sum_{i=1}^n (\mathbf{y}_i^T \mathbf{n})^2$$

<https://blog.csdn.net/linmingan>

其中：

$$\mathbf{y}_i = \mathbf{X}_i - m$$

PCA点云法向量估计

我们进一步对目标函数进行推导：

$$\begin{aligned}\min_{\mathbf{n}^T \mathbf{n} = 1} \sum_{i=1}^n (\mathbf{y}_i^T \mathbf{n})^2 &= \min_{\mathbf{n}^T \mathbf{n} = 1} \sum_{i=1}^n \mathbf{n}^T \mathbf{y}_i \mathbf{y}_i^T \mathbf{n} = \\ \min_{\mathbf{n}^T \mathbf{n} = 1} \mathbf{n}^T \left(\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T \right) \mathbf{n} &= \min_{\mathbf{n}^T \mathbf{n} = 1} \mathbf{n}^T (\mathbf{Y} \mathbf{Y}^T) \mathbf{n}\end{aligned}$$

上面的优化目标函数等于：

$$\begin{aligned}f(\mathbf{n}) &= \mathbf{n}^T \mathbf{S} \mathbf{n} \text{ 其中, } \mathbf{S} = (\mathbf{Y} \mathbf{Y}^T) \\ \min(f(\mathbf{n})) \\ \text{s.t. } \mathbf{n}^T \mathbf{n} &= 1\end{aligned}$$

$\mathbf{Y} \mathbf{Y}^T$ 是一个 3×3 的协方差矩阵， x ， y ， z 坐标的协方差矩阵

对于这种有约束的优化目标函数，我们可以用拉格朗日算法进行求解：

$$\mathcal{L}(\mathbf{n}, \lambda) = f(\mathbf{n}) - \lambda(\mathbf{n}^T \mathbf{n} - 1)$$

$$\nabla \mathcal{L} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{n}} = \frac{\partial}{\partial \mathbf{n}} f(\mathbf{n}) - \lambda \frac{\partial}{\partial \mathbf{n}} (\mathbf{n}^T \mathbf{n} - 1)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = \mathbf{n}^T \mathbf{n} - 1$$

$$\frac{\partial}{\partial \mathbf{n}} f(\mathbf{n}) - \lambda \frac{\partial}{\partial \mathbf{n}} (\mathbf{n}^T \mathbf{n} - 1) = (\mathbf{S} + \mathbf{S}^T) \mathbf{n} - \lambda (\mathbf{I} + \mathbf{I}^T) \mathbf{n} = 2\mathbf{S} \mathbf{n} - 2\lambda \mathbf{n}$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{n}} = 0 \iff \mathbf{S} \mathbf{n} = \lambda \mathbf{n}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = 0 \iff \mathbf{n}^T \mathbf{n} = 1$$

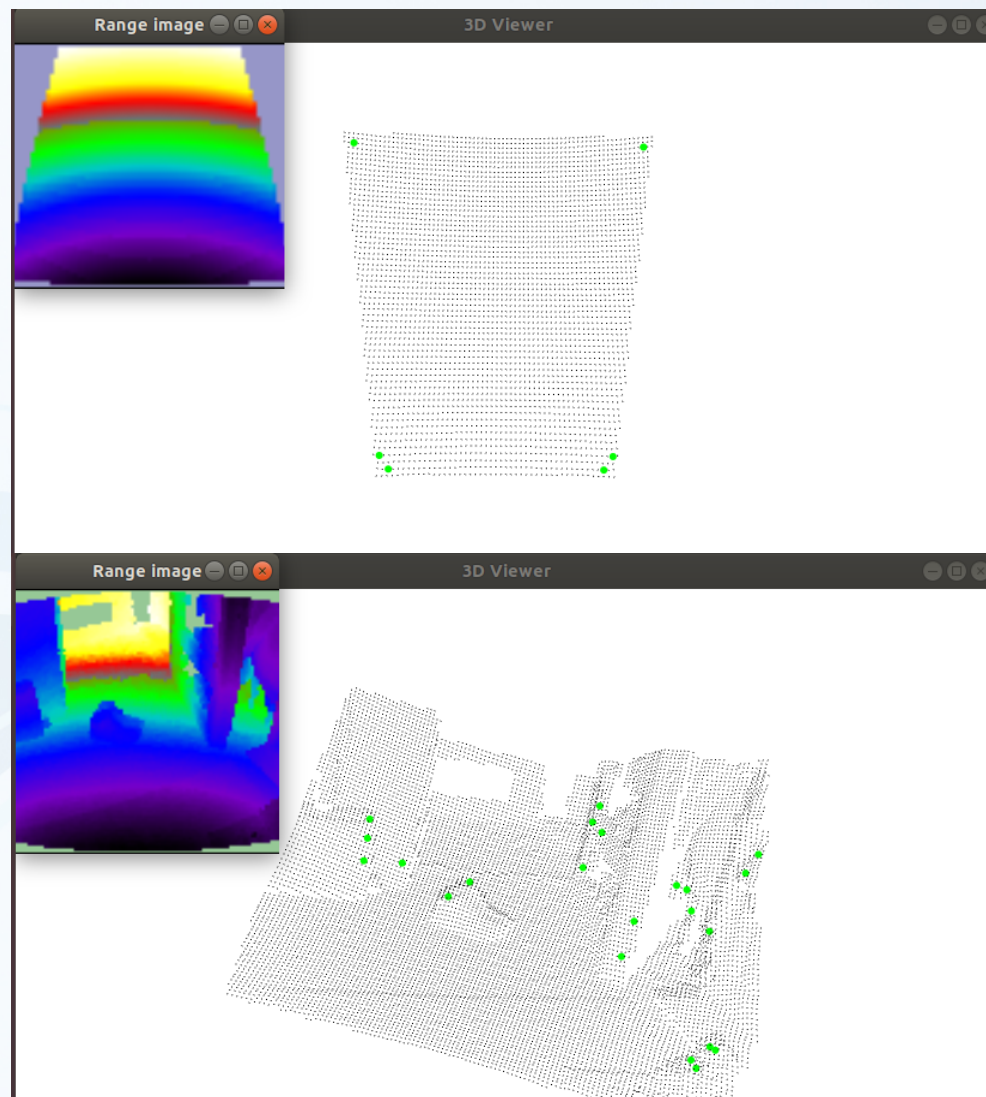
$\mathbf{S} \mathbf{n} = \lambda \mathbf{n}$?有没有很眼熟，其实就是线性代数里面的特征值和特征向量的相关公式。也即是， λ 是矩阵 \mathbf{S} 的特征值，法向量是对应的特征向量。

所以法向量 \mathbf{n} 的求解就是要对 \mathbf{S} 进行向量分解。然后取特征值最小的特征向量作为求解的法向量。这个过程也就是PCA的一个标准求解过程，将每个邻域点与该邻域的中心点相减，得到一个 $n \times 3$ 的矩阵。接着，用SVD对该矩阵进行分解，得到：

$$\mathbf{Y} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^*$$

\mathbf{U} 中最后一列就是要求解的法向量 \mathbf{n} ，也就是特征值最小的特征向量。

NARF特征点提取结果




二、Harris关键点

3.1 理论分析

边缘是图像中亮度变化不连续或突变的部分，即梯度幅值极大值的地方。而角点狭义上是图像中边缘变化不连续或突变的部分，即边缘曲线上曲率极大值的地方，简单来说，角点就是两条边缘的交点。边缘和角点都是图像中重要的特征。

由于 Harris 角点检测方法具有旋转不变性^①、尺度不变性^②、光照不变性^③，以及它的抗干扰能力强^④，所以它是一种非常流行的兴趣点 (interest point) 检测方法。该方法是由 Harris 和 Stephens 在 Moravec 角点检测算子的基础上于 1988 年提出的。

Harris 角点检测方法是基于局部信号的自相关函数。当一个小窗口在图像中的平坦区域移动时，窗口内的灰度值变化不剧烈；当窗口沿着边缘方向移动时变化也不剧烈，但当沿着边缘的正交方向移动时，变化会十分剧烈；当窗口在角点区域移动时，无论向哪个方向移动，都会引起剧烈的变化。局部自相关函数就具有能够检测到在各个方向上由信号位移所引起的微小变化的功能，如图 3-1 所示。



▲图 3-1 小窗口位移的 3 种情况

Harris 角点检测方法给出了上述 3 种情况下的数学方法。对于图像 $I(x, y)$ ，当窗体在点 (x, y) 处位移 $(\Delta x, \Delta y)$ 后，它的自相关函数为：

$$c(x, y) = \sum_{(u, v) \in W(x, y)} w(u, v) [I(u, v) - I(u + \Delta x, v + \Delta y)]^2 \quad (3-1)$$

式中， $W(x, y)$ 是以点 (x, y) 为中心的窗体， $w(u, v)$ 为加权函数，它既可以是常数，也可以是

泰勒公式: $f(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \dots + \frac{f^{(n)}(a)}{n!}(x-a)^n + R_n(x)$

高斯加权函数, 为了简化起见, 将 $\sum_{(u,v) \in R(x,y)} w(u,v)$ 表示为 Σ_w 。

根据泰勒展开, 对位移图像进行一阶近似:

$$I(u + \Delta x, v + \Delta y) \approx I(u, v) + [I_x(u, v) I_y(u, v)] \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \quad (3-2)$$

式中, $I_x(u, v)$ 和 $I_y(u, v)$ 分别为图像在 x 和 y 上的偏导数。把式 (3-2) 代入式 (3-1) 中, 得到:

$$\begin{aligned} c(x, y) &= \sum_w \left(I(u, v) - I(u, v) - [I_x(u, v) I_y(u, v)] \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right)^2 \\ &= \sum_w \left([I_x(u, v) I_y(u, v)] \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \right)^2 \\ &= [\Delta x \ \Delta y] \begin{bmatrix} \sum_w (I_x(u, v))^2 & \sum_w I_x(u, v) I_y(u, v) \\ \sum_w I_x(u, v) I_y(u, v) & \sum_w (I_y(u, v))^2 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \\ &= [\Delta x \ \Delta y] C(x, y) \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \quad (3-3) \end{aligned}$$

式中, $C(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$ 称为自相关矩阵, 它能够获取局部邻域内的结构强度。

设 λ_1 和 λ_2 为矩阵 $C(x, y)$ 的两个特征值, 分析表明, 两个特征值的大小与图像的结构有着密切的关系:

(1) 当 λ_1 和 λ_2 都很小时, 局部自相关函数 $c(x, y)$ 会十分“平坦”, 也就是在任何方向上位移时 $c(x, y)$ 变化都很小, 这表明邻域内的图像区域有近似一致的强度;

(2) 当特征值中一个很大而另一个很小时, 局部自相关函数是一个脊形, 也就是对于 $c(x, y)$ 在某一方向上 (沿着脊形) 的局部位移会引起很小的变化, 而在它的正交方向上会引起很大的变化, 这表明该局部是一个边缘;

(3) 当两个特征值都很大时, 局部自相关函数是一个尖峰, 也就是在各个方向上的位移都会引起剧烈的变化, 这表明该局部是一个角点。

因此只要确定自相关矩阵 $C(x, y)$ 的两个特征值的大小, 不仅能够判断出是否是角点, 还能够判断出是否是边缘。

对于矩阵 $C(x, y)$ 来说, 求它的特征值需要解一元二次方程, 这必然会降低运算效率。因此 Harris 和 Stephens 利用矩阵的性质, 用另一种方法来确定两个特征值 λ_1 和 λ_2 的相对大小, 而不需要确切地知道 λ_1 和 λ_2 的值, 即:

矩阵 $\begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$ 的行列式为 $\lambda_1\lambda_2$, 迹为 $\lambda_1+\lambda_2$

$$R = \lambda_1\lambda_2 - k(\lambda_1 + \lambda_2)^2 \quad (3-4)$$

式中, $\lambda_1\lambda_2$ 是自相关矩阵 $C(x, y)$ 的行列式的值, $(\lambda_1 + \lambda_2)$ 是 $C(x, y)$ 的迹值, 因此式 (3-4) 可以用下式表示:

$$R = \det(C(x, y)) - k(\text{trace}(C(x, y)))^2 \quad (3-5)$$

式中自相关矩阵 $C(x, y) = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$ 的行列式的值和它的迹值分别为:

$$\det(C(x, y)) = \lambda_1\lambda_2 = ac - b^2 \quad (3-6)$$

$$\text{trace}(C(x, y)) = \lambda_1 + \lambda_2 = a + c \quad (3-7)$$

式 (3-4) 和式 (3-5) 中的 k 为经验系数, 取值范围在 $0.04 \sim 0.06$ 。当 R 很大时, 像素在 (x, y) 位置上为角点; 当 R 为较大的负值时, 为边缘; 当 R 接近 0 时, 为平坦区域。

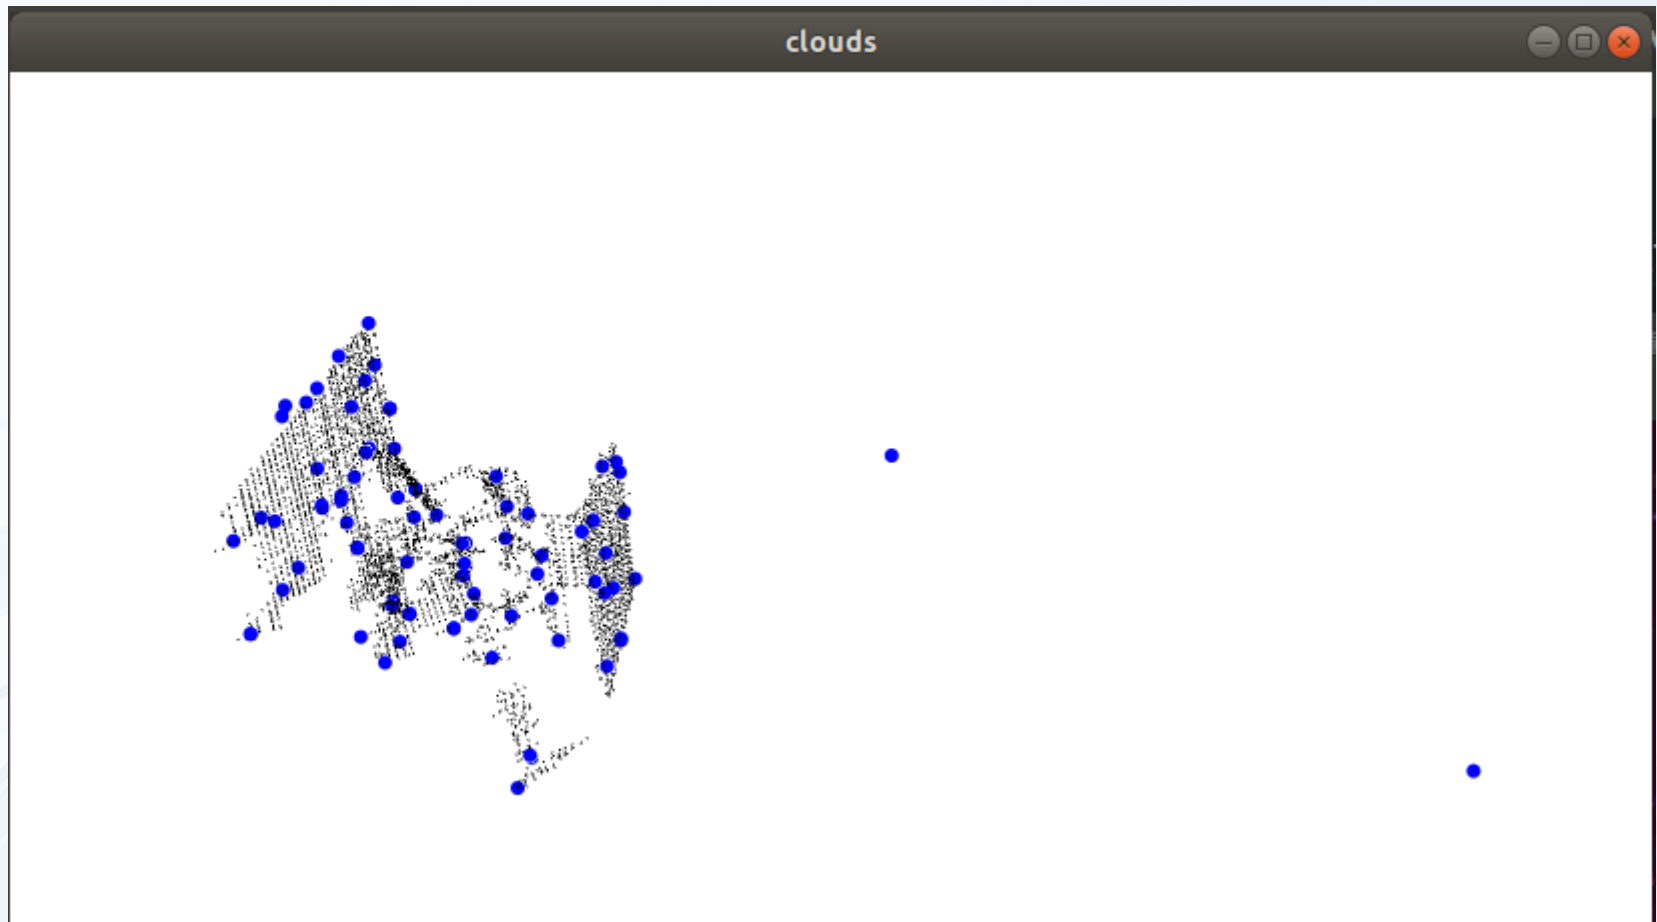
下面就总结一下 Harris 角点检测方法的一般步骤:

- (1) 计算图像 I 在水平方向和垂直方向上的梯度 I_x 和 I_y ;
- (2) 计算两个方向梯度的乘积 $I_x^2 = I_x I_x$ 、 $I_y^2 = I_y I_y$ 和 $I_{xy} = I_x I_y$;
- (3) 使用加权窗口 w (可以是高斯加权, 也可以是平均加权) 对 I_x^2 、 I_y^2 和 I_{xy} 进行加权处理, 得到自相关矩阵的元素 $a = I_x^2 \otimes w$ 、 $b = I_{xy} \otimes w$ 、 $c = I_y^2 \otimes w$;

(4) 利用式 (3-5) 求 R ;

(5) 设置一个阈值, 只有大于该阈值的 R 才被认为是角点。

Harris特征点提取结果



三、SIFT特征点


SIFT的全称是Scale Invariant Feature Transform，尺度不变特征变换，由加拿大教授David G.Lowe提出的。**SIFT**特征对旋转、尺度缩放、亮度变化等保持不变性，是一种非常稳定的局部特征。

注意：这个算法已经在美国申请了专利，所以不能随意使用。

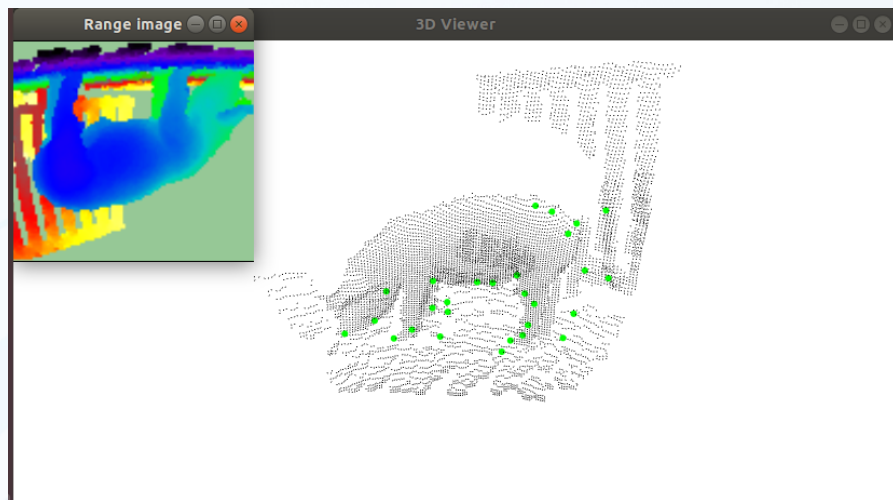
SIFT算法具的特点

- 1.图像的局部特征，对旋转、尺度缩放、亮度变化保持不变，对视角变化、仿射变换、噪声也保持一定程度的稳定性。
- 2.独特性好，信息量丰富，适用于海量特征库进行快速、准确的匹配。
- 3.多量性，即使是很少几个物体也可以产生大量的**SIFT**特征
- 4.高速性，经优化的**SIFT**匹配算法甚至可以达到实时性
- 5.扩展性，可以很方便的与其他特征向量进行联合。


三、SIFT特征点提取结果



四、同一点云，不同方法提取结果对比

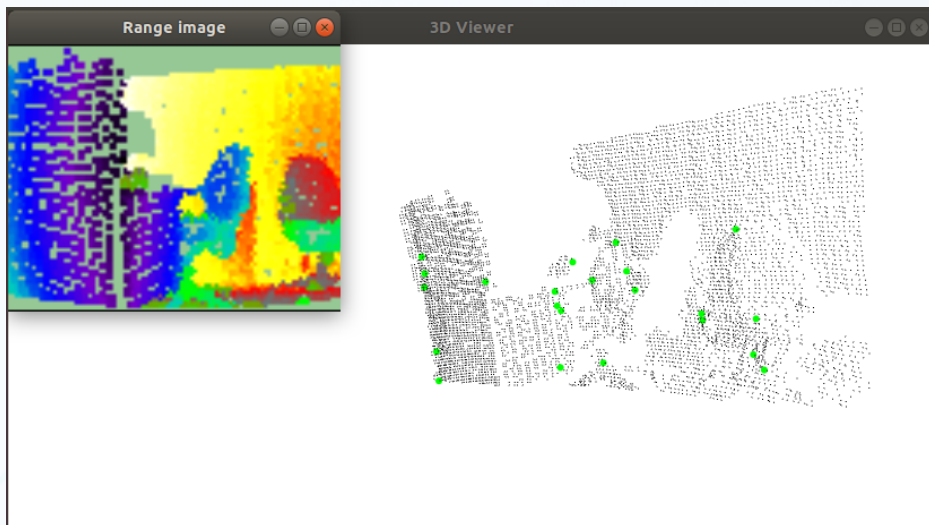


NARF特征点

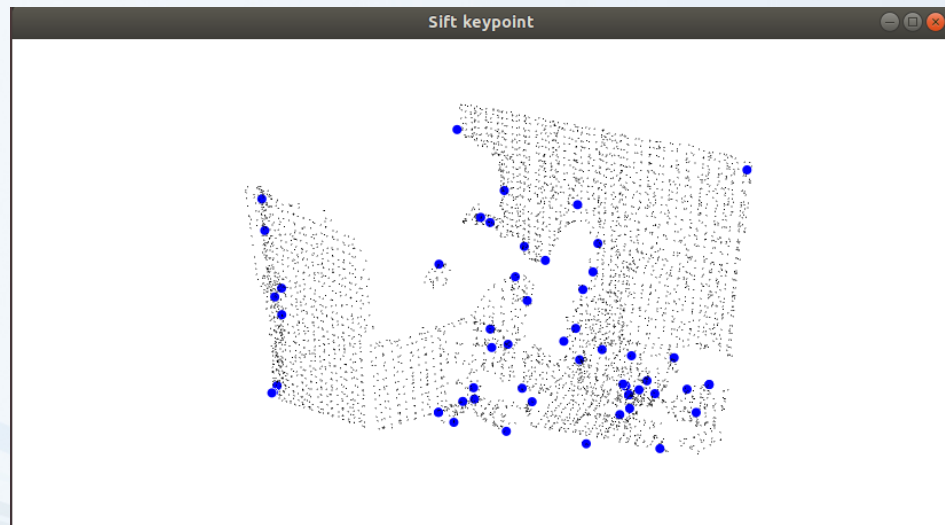


SIFT特征点

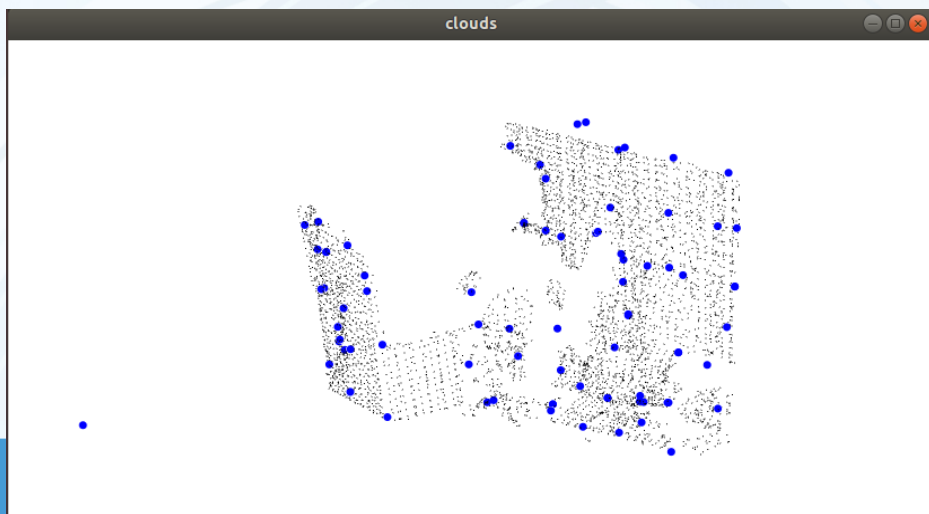
四、同一点云，不同方法提取结果对比



NARF特征点



SHIFT特征点



Harris特征点

THANKS



